

Exploración de modelos de Inteligencia Artificial multimodal para la identificación de macromicetos mediante dispositivos móviles

Delimitación, casos de uso y decisiones iniciales de arquitectura

Daniel Esteban Camacho Ospina
Cesar Augusto Pulido Cuervo

1. Delimitación del problema

El proyecto se plantea inicialmente como un problema de clasificación visual cerrada a nivel de género. En esta primera fase se trabajará con un grupo reducido de géneros que representen formas macroscópicas claramente diferentes, con el propósito de validar el pipeline completo de adquisición, preprocesamiento, entrenamiento, evaluación y despliegue móvil.

Esta etapa debe entenderse como una validación intergénero basada principalmente en diferencias morfológicas fuertes, y no todavía como un problema completo de clasificación visual fina. Una vez comprobado el funcionamiento del sistema, la dificultad podrá incrementarse mediante la incorporación de géneros visualmente cercanos y, sujeto a la disponibilidad y calidad de los datos, mediante clasificación a nivel de especie.

La aplicación se concibe como una herramienta de apoyo a la identificación y no como un sustituto de la determinación realizada por una persona experta. La predicción obtenida a partir de imágenes y variables contextuales no deberá utilizarse para establecer por sí sola la comestibilidad o seguridad de un espécimen.

2. Selección inicial de taxones

Para la primera aproximación se proponen diez géneros, con el objetivo de construir un punto de partida razonable para validar posteriormente el pipeline de clasificación.

La selección busca cubrir tres aspectos:

1. diversidad de formas macroscópicas;
2. presencia o relevancia documentada en fuentes de hongos de Colombia;
3. dificultad progresiva para el modelo.

En Colombia existe una diversidad amplia de cuerpos fructíferos, incluyendo hongos de repisa, estrellas de tierra y hongos con sombrero y pie [4]. El Catálogo de Hongos de Colombia presenta además ejemplos de géneros incluidos en esta selección, como *Hericium*, *Geastrum*, *Trametes*, *Morchella*, *Pleurotus*, *Xylaria* y *Auricularia* [5].

#	Género	Grupo	Razón para incluirlo inicialmente
1	<i>Trametes</i>	Basidiomycota	Presenta normalmente cuerpos fructíferos en forma de repisa sobre madera, muy diferentes de un hongo clásico con sombrero y pie. Es útil como una clase morfológicamente clara para comenzar. Además, en DF20 <i>Trametes versicolor</i> es la especie con mayor cantidad de imágenes: 1 913 registros [1]. Este dato se usa únicamente como referencia de disponibilidad en DF20 y no como evidencia de que sea la especie más abundante en Colombia.
2	<i>Ganoderma</i>	Basidiomycota	Incluye hongos de consistencia relativamente dura y crecimiento tipo repisa. Varias especies presentan una superficie superior brillante o lacada. Permite introducir otro grupo asociado a madera, pero con características visuales diferentes a <i>Trametes</i> . Los géneros <i>Ganoderma</i> y <i>Trametes</i> han sido registrados en estudios de macrohongos colombianos [6].
3	<i>Hericiium</i>	Basidiomycota	Posee cuerpos fructíferos con estructuras en forma de dientes o espinas colgantes. Esta geometría es muy diferente de las repisas y de los hongos lamelados, por lo que resulta útil para comprobar inicialmente si el modelo captura información global de forma. El Catálogo de Hongos de Colombia incluye registros e imágenes de <i>Hericiium erinaceus</i> [5].
4	<i>Auricularia</i>	Basidiomycota	Presenta cuerpos fructíferos gelatinosos, frecuentemente con apariencia auricular o lobulada. Introduce textura y forma distintas a las clases anteriores. Existen registros del género en Colombia y ejemplares estudiados en Tolima [4,6].
5	<i>Lycoperdon</i>	Basidiomycota	Representa los llamados <i>puffballs</i> , con cuerpos fructíferos aproximadamente globosos y sin la estructura convencional de sombrero y pie. Permite incluir una morfología cerrada y compacta. El género se encuentra documentado en colecciones colombianas [7].
6	<i>Geastrum</i>	Basidiomycota	Las estrellas de tierra presentan durante la madurez una capa externa que se abre formando segmentos alrededor del saco de esporas. Es una forma muy característica y diferente de las demás seleccionadas. El género se encuentra documentado en Colombia y aparece también en el Catálogo de Hongos de Colombia [5,7].
7	<i>Morchella</i>	Ascomycota	Permite incorporar un grupo de Ascomycota y no limitar la primera selección exclusivamente a Basidiomycota. Sus cuerpos fructíferos presentan una superficie con cavidades y crestas que produce un patrón reticulado particular. El género está documentado para Colombia [5,8].

#	Género	Grupo	Razón para incluirlo inicialmente
8	<i>Xylaria</i>	Ascomycota	Introduce otra morfología de Ascomycota. Sus cuerpos fructíferos pueden ser oscuros, alargados o ramificados, generando una estructura visual muy distinta de las clases anteriores. Existen registros del género en colecciones y catálogos colombianos [4,5].
9	<i>Pleurotus</i>	Basidiomycota	Permite comenzar a introducir hongos lamelados. Normalmente presenta crecimiento lateral o excéntrico y puede aparecer agrupado sobre madera. Funciona como transición entre las morfologías muy particulares anteriores y el problema de diferenciar hongos con láminas. El género también ha sido registrado en muestreos realizados en Tolima [6].
10	<i>Amanita</i>	Basidiomycota	Introduce una morfología más cercana al hongo clásico de sombrero y pie. Su inclusión aumenta la dificultad y sirve como transición hacia la clasificación visual fina entre especies de aspecto parecido. Esta elección tiene además respaldo metodológico en DF20-Mini: <i>Amanita</i> es uno de los seis géneros seleccionados por sus autores para construir un subconjunto deliberadamente difícil de clasificación fina [1].

Con estos géneros se busca comprobar que el pipeline puede aprender diferencias grandes de estructura. Una vez verificado esto, el problema podrá hacerse progresivamente más difícil.

En este esquema:

- *Trametes*, *Ganoderma*, *Hericiium*, *Auricularia*, *Lycoperdon*, *Gaeastrum*, *Morchella* y *Xylaria* proporcionan diversidad morfológica fuerte;
- *Pleurotus* introduce una morfología lamelada relativamente diferente por su crecimiento lateral;
- *Amanita* acerca el experimento al problema de clasificación fina de hongos con sombrero y pie.

Esta estrategia busca validar primero el sistema con diversidad morfológica y solo después aumentar la dificultad dentro de grupos visualmente cercanos.

3. Casos de uso

Los casos de uso se definen para que el sistema pueda funcionar como herramienta de apoyo a la identificación taxonómica de macromicetos y, al mismo tiempo, como plataforma experimental para evaluar el aporte de distintas modalidades de información.

3.1. Caso de uso 1: identificación en campo

Este es el caso de uso objetivo y principal. El usuario encuentra un macromiceto, toma una fotografía con el dispositivo móvil y obtiene una predicción taxonómica acompañada por información

sobre la confianza del modelo. Durante la primera fase, la salida corresponderá a uno de los diez géneros considerados o a una abstención cuando la evidencia sea insuficiente.

El flujo básico será:

captura → preprocesamiento → modelo → predicción taxonómica

La aplicación deberá conservar una ruta de inferencia local que funcione sin conexión a Internet. Como mínimo, el sistema deberá poder generar una predicción utilizando únicamente la imagen. Posteriormente se contemplará el funcionamiento con las variables adicionales incluidas en los modelos M_B , M_C y M_D .

La interfaz deberá informar que el resultado constituye una ayuda a la identificación y no una certificación taxonómica ni una recomendación de consumo. También podrá solicitar fotografías adicionales de estructuras relevantes cuando la imagen inicial no sea suficiente.

3.2. Caso de uso 2: identificación multimodal

El sistema permitirá estudiar si la información contextual mejora la clasificación obtenida solamente con imágenes.

Para esto se plantea una comparación incremental:

$$\begin{aligned}M_A &= f(I), \\M_B &= f(I, G), \\M_C &= f(I, G, C), \\M_D &= f(I, G, C, S),\end{aligned}$$

Donde:

- I : imagen;
- G : geolocalización;
- C : variables climáticas;
- S : sustrato.

Para aislar el aporte de cada modalidad, las comparaciones conservarán, en lo posible, el mismo extractor visual, las mismas particiones de datos y una estrategia común de entrenamiento. Las modalidades adicionales se incorporarán mediante representaciones de baja dimensión que serán fusionadas con la representación visual antes de la clasificación.

Cada modalidad deberá admitir valores ausentes. En particular, la falta de geolocalización, clima o sustrato no deberá impedir el uso del modelo visual M_A . La procedencia, resolución temporal y disponibilidad sin conexión de las variables climáticas se definirán cuando se establezca la fuente de datos.

3.3. Caso de uso 3: manejo de predicciones con baja confianza

El sistema deberá poder identificar situaciones en las cuales la evidencia no sea suficiente para producir una predicción confiable.

En estos casos podrá:

- reportar baja confianza;
- abstenerse de entregar un género;
- devolver una predicción en un nivel taxonómico superior;
- presentar varias alternativas ordenadas;
- solicitar fotografías o información contextual adicional.

La calibración de probabilidades, la política de abstención y la evaluación exploratoria frente a observaciones no conocidas se tratarán como problemas relacionados, pero distintos. Una probabilidad máxima baja podrá utilizarse como señal inicial de incertidumbre, pero no se interpretará por sí sola como prueba de que una observación pertenece a una clase desconocida.

4. Criterios de éxito

Estos criterios no se determinarán mediante una única cifra de exactitud. Se evaluarán desde cinco dimensiones principales:

1. calidad predictiva;
2. aporte real de la multimodalidad;
3. robustez e incertidumbre;
4. viabilidad de ejecución móvil;
5. reproducibilidad.

4.1. Desempeño predictivo

El modelo deberá producir resultados útiles no solamente sobre las clases más frecuentes. La métrica principal será macro-F1, acompañada por exactitud global, exactitud balanceada, métricas por clase y matriz de confusión. También podrá considerarse exactitud top- k para analizar si el género correcto aparece entre las primeras alternativas.

El proyecto será considerado exitoso en este punto si permite comparar los modelos de forma reproducible y evita que un buen resultado global oculte un mal desempeño sobre clases minoritarias.

4.2. Aporte de las modalidades

Una modalidad adicional solamente se considerará útil si produce una mejora medible respecto al modelo inmediatamente anterior.

$$M_A \rightarrow M_B \rightarrow M_C \rightarrow M_D$$

Por tanto, también será un resultado válido descubrir que una modalidad no mejora el desempeño. Las comparaciones deberán informar la diferencia entre modelos bajo las mismas particiones y condiciones de entrenamiento, además de la variabilidad observada entre repeticiones.

4.3. Robustez frente al desbalance

El modelo deberá evaluarse separando clases frecuentes y clases con pocas observaciones. No será suficiente mejorar únicamente las clases dominantes del conjunto de datos.

Se analizarán como mínimo:

- métricas por clase;
- desempeño según frecuencia de clase;
- matriz de confusión;
- macro-F1 y exactitud balanceada.

Una arquitectura será preferible si mantiene un rendimiento razonable entre diferentes grupos de frecuencia y no depende únicamente de las clases con más ejemplos.

4.4. Incertidumbre y abstención

Las probabilidades del modelo deberán analizarse para evitar interpretar una salida de alta probabilidad como confianza válida sin comprobar su calibración.

El proyecto deberá evaluar:

- calibración de probabilidades;
- comportamiento en predicciones de baja confianza;
- establecimiento de un umbral de abstención usando el conjunto de validación;
- relación entre riesgo y cobertura;
- comportamiento frente a clases poco frecuentes;
- comportamiento exploratorio frente a observaciones no conocidas.

El objetivo es que el modelo pueda reconocer cuándo su predicción no tiene evidencia suficiente y comunicar incertidumbre o abstenerse, en lugar de forzar siempre una respuesta.

4.5. Viabilidad en dispositivo móvil

El modelo seleccionado deberá poder ejecutarse en al menos un dispositivo móvil de referencia y deberá conservar una ruta de inferencia compatible con CPU. Después de la conversión y optimización se medirán:

- cambio en calidad predictiva;
- tamaño del modelo;
- memoria consumida;
- latencia de carga e inferencia;
- compatibilidad con el runtime móvil;

- estabilidad durante inferencias repetidas.

La optimización será considerada exitosa si reduce el costo del modelo sin producir una degradación que elimine la ventaja predictiva obtenida. No se fija todavía un valor obligatorio de precisión o latencia porque estos umbrales deberán definirse después de conocer el conjunto de datos, disponer de un primer prototipo exportable y seleccionar el hardware de referencia.

4.6. Reproducibilidad

Finalmente, el proyecto será considerado exitoso únicamente si los resultados pueden reproducirse. Por ello deberán quedar documentados:

- conjunto de datos utilizado;
- reglas de inclusión y exclusión;
- unidad utilizada para separar observaciones;
- particiones de entrenamiento, validación y prueba;
- versión del conjunto de datos;
- arquitectura utilizada;
- configuración de entrenamiento;
- métricas;
- versión del modelo exportado;
- runtime y configuración de inferencia;
- dispositivo utilizado para las pruebas móviles.

Las particiones deberán impedir que fotografías pertenecientes a una misma observación aparezcan simultáneamente en entrenamiento y prueba. Cuando los datos lo permitan, también se estudiarán particiones agrupadas por localidad, fecha o recolector para reducir posibles fugas de información contextual.

5. Arquitecturas candidatas

5.1. Criterios de selección

Las arquitecturas candidatas se seleccionan considerando que el sistema deberá ejecutarse localmente en un dispositivo móvil de costo moderado. Por tanto, no se buscará únicamente maximizar la calidad predictiva, sino estudiar el compromiso entre:

$$\text{calidad predictiva} \longleftrightarrow \text{costo computacional} \longleftrightarrow \text{accesibilidad}$$

Los principales criterios de comparación serán:

- macro-F1 y desempeño por clase;

- calibración y capacidad de abstención;
- tamaño del modelo exportado;
- latencia de inferencia en CPU;
- memoria máxima utilizada;
- compatibilidad con el runtime móvil;
- degradación después de la cuantización.

El número de parámetros y las operaciones teóricas se usarán como descriptores, pero no sustituirán las mediciones realizadas directamente en el dispositivo. La arquitectura final deberá ubicarse en un compromiso favorable entre calidad y costo, y no necesariamente corresponderá al modelo con mayor exactitud.

5.2. Modelos considerados

Se propone limitar inicialmente la comparación a tres arquitecturas orientadas a dispositivos móviles y una arquitectura de referencia académica.

Arquitectura	Papel experimental	Justificación inicial
MobileNetV3-Large	Candidata móvil principal	Fue diseñada buscando un compromiso entre exactitud y latencia en dispositivos móviles. Proporciona una base adecuada para estudiar transferencia de aprendizaje y posterior cuantización [10].
EfficientNet-Lite0	Alternativa CNN eficiente	Pertenece a una familia adaptada para ejecución en dispositivos móviles y de borde. La variante Lite0 permite comenzar con el nivel de menor costo dentro de la familia y aumentar capacidad si los resultados lo justifican [11].
MobileViT-XXS	Alternativa híbrida	Combina operaciones convolucionales con mecanismos tipo transformer para representar información local y global. Su inclusión permite comparar las CNN móviles con una familia híbrida ligera [12].
ResNet-18	Baseline académico	Servirá como referencia para analizar la pérdida o ganancia obtenida al emplear arquitecturas específicamente orientadas a dispositivos móviles. Su inclusión no implica que deba desplegarse como modelo final [9].

En la primera comparación se utilizarán versiones preentrenadas y una estrategia común de ajuste fino. Se mantendrán, en lo posible, la misma resolución de entrada, aumentos de datos, particiones, función de pérdida y protocolo de evaluación, de modo que las diferencias observadas puedan atribuirse principalmente a la arquitectura.

5.3. Integración multimodal

Cada arquitectura candidata funcionará como extractor visual. La representación generada para la imagen se combinará con representaciones de baja dimensión de la geolocalización, las variables climáticas y el sustrato.

Se propone inicialmente una estrategia de fusión tardía: cada modalidad se procesará de manera independiente y sus representaciones se concatenarán antes del clasificador final. Este diseño permite conservar M_A como ruta visual autónoma y facilita comparar incrementalmente M_B , M_C y M_D .

Las dimensiones de las representaciones, las capas del módulo de fusión y el tratamiento definitivo de datos ausentes se establecerán después de conocer la estructura, distribución y completitud del conjunto de datos.

5.4. Optimización para inferencia móvil

Las arquitecturas que mantengan un desempeño competitivo serán convertidas a un formato compatible con el runtime móvil seleccionado. La evaluación considerará inicialmente:

1. una versión de referencia en precisión flotante;
2. cuantización posterior al entrenamiento en precisión reducida;
3. cuantización entera, cuando las operaciones y el hardware lo permitan;
4. entrenamiento consciente de cuantización si la optimización posterior al entrenamiento produce una degradación excesiva.

La cuantización se entiende como una estrategia experimental para reducir tamaño y costo de inferencia, no como una garantía automática de aceleración. Cada variante deberá volver a evaluarse en calidad predictiva y en el dispositivo objetivo [15].

6. Restricciones del dispositivo objetivo

6.1. Criterio de accesibilidad

En esta etapa no se selecciona un modelo comercial específico como único dispositivo objetivo. Aunque el desarrollo pueda realizarse utilizando un teléfono de gama media-alta disponible para el equipo, la aplicación busca ser utilizable en territorio por personas no especializadas y con acceso a dispositivos de costo moderado.

La clasificación comercial de un teléfono como gama baja, media o alta no constituye por sí sola una especificación técnica reproducible. Por ello, el dispositivo objetivo se define inicialmente mediante un perfil funcional, y la selección posterior del hardware de referencia se realizará considerando capacidades medibles.

6.2. Perfil funcional provisional

El perfil inicial contempla:

- sistema operativo Android;

- arquitectura de procesador ARM de 64 bits;
- cámara trasera con enfoque automático;
- capacidad de geolocalización;
- ejecución local del modelo visual;
- compatibilidad con inferencia mediante CPU;
- uso opcional, pero no obligatorio, de GPU, NPU o DSP;
- funcionamiento del modelo M_A sin conexión a Internet;
- manejo explícito de modalidades contextuales ausentes.

El modelo visual deberá conservar una ruta de inferencia compatible con CPU. Los aceleradores de hardware se considerarán optimizaciones opcionales debido a que su disponibilidad y compatibilidad varían entre fabricantes y dispositivos. La aplicación deberá poder volver a la ejecución en CPU cuando un acelerador no esté disponible o no soporte alguna operación.

Las variables climáticas no dependerán obligatoriamente de sensores ambientales integrados en el teléfono, pues estos no están presentes en todos los dispositivos Android [13,17]. Su fuente y estrategia de disponibilidad sin conexión se definirán posteriormente.

6.3. Niveles de evaluación

Para separar el dispositivo utilizado durante el desarrollo del perfil de los usuarios esperados, se contemplan tres niveles:

1. **dispositivo de referencia:** equipo disponible para desarrollar, exportar, depurar y ejecutar las primeras mediciones;
2. **dispositivo objetivo:** teléfono de gama media y costo moderado que represente el escenario principal de uso;
3. **dispositivo mínimo experimental:** equipo de menores prestaciones utilizado para explorar los límites de accesibilidad y la degradación de la experiencia.

Estos niveles cumplen funciones experimentales y no se interpretarán como categorías comerciales rígidas. Siempre que sea posible, las pruebas se realizarán en más de un dispositivo para evitar que la selección final dependa de un único fabricante o acelerador.

6.4. Restricciones por determinar

Los siguientes valores se establecerán después de contar con un primer modelo exportable y realizar mediciones preliminares:

- versión mínima de Android;
- memoria RAM mínima recomendada;
- tamaño máximo aceptable del modelo;
- latencia máxima tolerable;

- resolución definitiva de entrada;
- runtime móvil y versión utilizados;
- número de hilos de ejecución;
- delegados de aceleración compatibles;
- consumo energético y comportamiento térmico aceptables;
- degradación máxima permitida después de la optimización.

Las mediciones incluirán tiempo de carga, latencia de inferencia, memoria pico y comportamiento durante ejecuciones repetidas. Para ello podrán utilizarse las herramientas de medición del runtime seleccionado, como las disponibles para LiteRT, en lugar de depender únicamente del tiempo observado desde la interfaz [16].

7. Decisiones metodológicas pendientes

Antes de cerrar el diseño experimental deberán definirse los siguientes aspectos:

- fuente principal y licencia de las imágenes;
- número mínimo de observaciones aceptado por género;
- procedimiento de validación taxonómica;
- representación y procedencia de geolocalización, clima y sustrato;
- unidad utilizada para construir las particiones de datos;
- dispositivo o conjunto de dispositivos de referencia;
- runtime móvil definitivo;
- umbrales de aceptación, abstención y viabilidad móvil.

DF20 podrá utilizarse como referencia metodológica y, si resulta pertinente, como fuente para experimentos iniciales o preentrenamiento. Sin embargo, su procedencia geográfica no sustituye la necesidad de evaluar el sistema con datos representativos del contexto colombiano [1,2].

Links consultados

- [1] https://openaccess.thecvf.com/content/WACV2022/html/Picek_Danish_Fungi_2020_-_Not_Just_Another_Image_Recognition_Dataset_WACV_2022_paper.html
- [2] <https://sites.google.com/view/danish-fungi-dataset>
- [3] <https://revistas.udea.edu.co/index.php/actbio/article/view/346103>
- [4] <https://pmc.ncbi.nlm.nih.gov/articles/PMC10848862/>
- [5] <https://biodiversidadcop16.foronacionalambiental.org.co/wp-content/uploads/2024/07/Catalogue-of-Fun.pdf>

- [6] <https://pmc.ncbi.nlm.nih.gov/articles/PMC10222830/>
- [7] https://ipt.biodiversidad.co/permisos/resource?r=hongos_colombia_2021_1
- [8] <https://colfungi.org/taxon/urn%3Aisid%3Aindexfungorum.org%3Anames%3A3268>
- [9] <https://arxiv.org/abs/1512.03385>
- [10] https://openaccess.thecvf.com/content_ICCV_2019/html/Howard_Searching_for_MobileNetV3_ICCV_2019_paper.html
- [11] <https://github.com/tensorflow/tpu/tree/master/models/official/efficientnet/lite>
- [12] <https://machinelearning.apple.com/research/vision-transformer>
- [13] <https://developer.android.com/reference/android/hardware/SensorManager>
- [14] <https://onnxruntime.ai/docs/tutorials/mobile/>
- [15] https://developers.google.com/edge/litert/conversion/tensorflow/quantization/model_optimization
- [16] <https://developers.google.com/edge/litert/models/measurement>
- [17] https://developer.android.com/develop/sensors-and-location/sensors/sensors_environment