

Exploración de modelos de Inteligencia Artificial multimodal para la identificación de macromicetos mediante dispositivos móviles

Resultados de la Semana 2: auditoría y curaduría de datasets

Daniel Esteban Camacho Ospina
Cesar Augusto Pulido Cuervo

1. Objetivo de la semana

Esta semana se realizó el inventario y la auditoría inicial de las fuentes de datos de hongos disponibles para el proyecto: cuántas imágenes y observaciones existen, qué metadatos ofrece cada fuente, cuántos valores faltan, qué duplicados aparecen, cómo es el desbalance entre clases y qué riesgos presenta cada fuente.

2. Qué se hizo en el repositorio

- Se estructuró el repositorio para que los datos originales vivan solamente en local y no se versionen, por su tamaño y por las licencias de las fotografías.
- Se automatizó la adquisición de datos descargando únicamente metadatos, índices, taxonomías y respuestas de las interfaces de consulta (unos 0,7 GB en total). No se descargó ninguna imagen. El procedimiento es repetible y registra origen, fecha, tamaño y huella de verificación de cada archivo.
- Se programó una auditoría común para todas las fuentes, con un adaptador por dataset, que calcula tamaños, valores faltantes, duplicados y desbalance de clases.
- Se construyó un inventario con una fila por fuente. Toda cifra se etiqueta según su origen: *reportada por la fuente, calculada por nosotros sobre archivos locales, derivada o no verificada*. Así no se presentan como comprobadas cifras que solo provienen de una descripción.
- Se redactaron un informe técnico detallado y un cuaderno de análisis que permiten repetir la auditoría desde cero.

Se distingue siempre entre imagen y observación (un mismo hallazgo puede tener varias fotografías), para no inflar el tamaño efectivo de los datos ni contaminar las particiones futuras.

3. Fuentes revisadas

Se revisaron siete fuentes enfocandonos en la disponibilidad de los metadatos.

Fuente	Estado	Hallazgo principal
FungiTastic	Metadatos completos en local.	Los datos de clima no fueron accesibles.
DF20	Metadatos completos en local	Casi todo su contenido ya está incluido en FungiTastic.
MIND.Funga v2	Índice de archivos en local; requiere revisión	Contexto neotropical, pero sin agrupación por observación, sin coordenadas ni fecha, con posibles imágenes repetidas y licencia no comercial.
iNaturalist (API y Open Data)	Consultable de forma remota	Fotografías con licencia por imagen. La tabla de observaciones no incluye el país, por lo que Colombia debe filtrarse por coordenadas.
SiB Colombia (tres recursos)	Recursos completos en local	Ninguno de los tres contiene fotografías enlazadas.
GBIF	Consultable de forma remota	Cerca de la mitad de los registros colombianos con imagen provienen de iNaturalist.
Mushroom Observer	Metadatos completos en local	Amplia cobertura; identificación comunitaria y licencia por imagen.

4. Resultados principales

4.1. Tamaño: observaciones e imágenes

Fuente	Observaciones	Imágenes	Especies
FungiTastic	346 459	633 114	4 418
DF20	177 170	295 938	1 577
MIND.Funga v2	sin dato	18 023	509 carpetas
Mushroom Observer (hongos)	608 302	1 924 184	17 986
Mushroom Observer (Colombia)	21 019	61 351	592
iNaturalist (Colombia) ^a	127 886	no calculado	2 447
GBIF (Colombia, con imagen) ^a	21 638 registros	no calculado	no calculado
SiB Colombia (tres recursos)	1 706 registros	0	—

4.2. Valores faltantes

- **FungiTastic y DF20:** muy completos. El sustrato falta en 4,85 % de las imágenes de FungiTastic y en 0,52 % de las de DF20; especie, género, fecha y coordenadas casi no presentan ausencias. Se tiene la limitación de imposibilidad de descarga de climate.zip pues no existe en los servidores en la fecha consultada.
- **Mushroom Observer (Colombia):** 88 % de las observaciones no llega a especie, 46 % no llega a género y 47 % no tiene coordenadas.
- **SiB Colombia:** un recurso presenta coordenadas corruptas por separadores decimales mal aplicados (más de 900 valores fuera de rango), otro no trae coordenadas y sus fechas son internamente contradictorias, y dos de los tres usan fechas en formato no estándar.
- **MIND.Funga:** no incluye observación, coordenadas, fecha, sustrato ni hábitat; solo la imagen y su carpeta de taxón.

4.3. Disponibilidad de los diez géneros propuestos

Como verificación complementaria, se consultó cuántos datos existen para los diez géneros de la selección inicial.

Género	FungiTastic (entren.)	DF20	MIND.Funga	Mushroom Observer (Col.)	iNaturalist (Col.) ^b
<i>Trametes</i>	6 626	4 264	318	460	785
<i>Ganoderma</i>	3 567	2 499	140	840	119
<i>Hericium</i>	826	679	0	6	7
<i>Auricularia</i>	2 106	1 387	389	748	213
<i>Lycoperdon</i>	3 336	2 779	20	226	95
<i>Geastrum</i>	1 350	1 011	346	434	29
<i>Morchella</i>	405	173	0	14	182
<i>Xylaria</i>	2 758	1 641	261	1 049	117
<i>Pleurotus</i>	2 690	1 704	166	888	31
<i>Amanita</i>	6 508	5 370	130	669	2 288

Imágenes por género, salvo ^b observaciones de grado de investigación (no imágenes). FungiTastic y DF20 son de origen europeo.

Los diez géneros están bien representados en las fuentes europeas, pero *Hericium* y *Morchella* son casi inexistentes en las fuentes colombianas con imágenes, y *Amanita* domina de forma desproporcionada en iNaturalist Colombia. Esto deberá considerarse al decidir con qué datos se evalúa el contexto colombiano.

5. Limitaciones

- **Licencias:** FungiTastic declara tres licencias distintas; MIND.Funga es de uso no comercial; iNaturalist, GBIF y Mushroom Observer tienen licencia por imagen, con variantes que limitan el uso.
- **Alcance:** los datasets grandes son casi exclusivamente daneses; el reino Fungi incluye líquenes y otros hongos no macroscópicos; muchos registros colombianos son especímenes de colección y no fotografías de campo.
- **Clima:** Algo muy importante que podría afectar al ultimo modelo que se pretendía evaluar es no tener data exacta de clima como se preveía que tenía FungiTastic, ante la ausencia de esta en el servidor.

6. Conclusiones

Los dataset técnicamente utilizables son: FungiTastic y, en menor medida, DF20. Estos tienen metadatos completos y consistentes, pero de contexto europeo y solapados entre sí. iNaturalist, GBIF y Mushroom Observer como vías para datos colombianos. Además, los tres recursos de SiB Colombia que fueron revisados son descartados para entrenamiento, por no contener fotografías.