Exploración de modelos de Inteligencia Artificial multimodal para la identificación de macromicetos mediante dispositivos móviles

Resultados de las Semanas 5 y 6: ajuste del modelo visual y análisis taxonómico

Daniel Esteban Camacho Ospina
Cesar Augusto Pulido Cuervo

1. Objetivo y protocolo de evaluación

La Semana 5 busca entrenar una arquitectura apta para dispositivos móviles, ajustar su configuración y estudiar el desequilibrio entre géneros. La Semana 6 amplía la evaluación a familia, orden, clase y filo y organiza el código para incorporar posteriormente información ambiental.

Se utiliza exclusivamente FungiTastic en la versión `v002`, con diez géneros y las particiones oficiales: 17 799 observaciones de entrenamiento, 3 452 de validación y 4 039 de test, para un total de 25 290. Hay, respectivamente, 30 172, 6 290 y 7 159 fotografías. Se conservan las particiones oficiales para mantener un protocolo común entre los modelos.

(`reports/s5/comparison/imbalance_ratios.csv`).

Una observación agrupa las fotografías del mismo registro de un hongo. El modelo predice probabilidades por foto; para decidir el género de la observación se promedian esas probabilidades, con el mismo peso para cada foto, y se elige el género con el mayor promedio:

$$\overline{p}_o(g) = \frac{1}{m_o} \sum_{i \in o} p_i(g), \qquad \widehat{g}_o = \arg\max_g \overline{p}_o(g).$$

La decisión utiliza así la información conjunta de las fotografías del registro. La misma regla se aplica a ResNet-18 y a los ensayos A, B, C y D.

(`scripts/train/metrics.py`).

La métrica principal es el **F1 macro por observación**: se calcula el F1 de cada género y se promedian los resultados con igual peso por género. La *precisión* mide qué proporción de las observaciones asignadas a un género pertenece realmente a él; la *recuperación* o *recall* mide qué proporción de las observaciones reales de ese género se encuentra. El F1 combina ambas. La exactitud o porcentaje de aciertos da, en cambio, el mismo peso a cada observación y por eso está más influida por los géneros abundantes.

(`scripts/train/metrics.py`).

Las decisiones de S5 se toman únicamente con validación. La comparación de A–D corresponde a esa partición. La evaluación de test del MobileNet seleccionado se realizará una sola vez, una vez cerrados los ajustes. Los resultados de test de ResNet-18 proceden de la fase anterior y se presentan como antecedente; no intervienen en la elección del modelo móvil. Esta exposición histórica limita el carácter completamente ciego del test durante el conjunto del proyecto.

(`reports/s5/comparison/run_inventory.csv`).

2. Semana 5: configuración y resultados del modelo móvil

2.1. Arquitectura y coste de ejecución

Los ensayos A–D conservan MobileNetV3-Large, inicializado con los pesos `IMAGENET1K_V1` y una salida para los géneros del dataset. ResNet-18 es la arquitectura de referencia. Se reajustan todos los parámetros: no se congelan capas del extractor visual.

(`scripts/train/pipeline/models.py`).

(`scripts/train/pipeline/training.py`).

Cuadro 1: Perfil histórico en CPU del PC, FP32, lote unitario y entrada sintética. No incluye preparación de la foto ni ejecución en Android.

Arquitectura	**Parámetros**	**Pesos (MB)**	**Mediana (ms/foto)**
ResNet-18	11 181 642	44,804	37,104
MobileNetV3-Large	4 214 842	17,060	20,696

(`reports/s5/architecture_profile.json`).

Con los valores completos del perfil, la razón de latencias es 37,104/20,696 $\approx$ 1,793: MobileNet necesita menos tiempo por entrada en esa medición. Sus pesos serializados ocupan un 61,923 % menos espacio. Se reutiliza el perfil porque B, C y D no modifican la arquitectura ni su número de salidas. El archivo medido contiene los pesos del modelo, no el estado del optimizador.

(`reports/s5/comparison/profile_ratios.json`).

La medición histórica corresponde a CPU, FP32, un tensor sintético por lote y cuatro hilos; utiliza cinco iteraciones de calentamiento y treinta medidas. Excluye la preparación de fotografías y emplea pesos aleatorios para caracterizar la arquitectura. Por tanto, no mide la aplicación completa ni demuestra esa misma razón de velocidad en Android.

(`reports/s5/architecture_profile.json`).

2.2. Configuración de los ensayos A, B, C y D

Cuadro 2: Configuración de los ensayos. Negrita: ajustes que cambian respecto de A. Se indica el lote de validación utilizado en cada entorno.

Ajuste	A	B	C	D
Aprendizaje inicial	0,0003	**0,0001**	0,0003	**0,0001**
Pesos por clase	Ninguno	Ninguno	$1/\sqrt{n_c}$	$1/\sqrt{n_c}$
Fotos por paso	64	64	64	64
Lote de validación	128	**64**	**64**	**64**
Entrada (píxeles)	224 × 224	224 × 224	224 × 224	224 × 224
Máximo de vueltas	30	30	30	30
Paciencia	5	5	5	5
Optimizador	AdamW	AdamW	AdamW	AdamW
Decaimiento de pesos	0,05	0,05	0,05	0,05
Suavizado de etiquetas	0,1	0,1	0,1	0,1
Programa de aprendizaje	Coseno	Coseno	Coseno	Coseno
Calentamiento (vueltas)	1	1	1	1
Procesos de carga	4	4	4	4
Semilla	42	42	42	42
Determinismo exigido	No	No	No	No
Precisión efectiva	FP32	**AMP**	**AMP**	**AMP**
Capas congeladas	Ninguna	Ninguna	Ninguna	Ninguna

(`reports/s5/comparison/configuration.csv`).

B reduce la tasa de aprendizaje respecto de A. C conserva la tasa de A y añade pesos por clase; D combina la tasa menor y esos pesos. La ponderación es inversamente proporcional a la raíz del número de fotos de entrenamiento de cada género, normalizada para que la media de los pesos sea uno. Se calcula solo con `train`; ni la validación ni el test determinan los pesos.

(`scripts/train/pipeline/training.py`).

El aumento de datos es común: recorte aleatorio con escala entre 0,5 y 1,0, reflexión horizontal y variación de color con parámetros $(0{,}2; 0{,}2; 0{,}2; 0{,}02)$. La normalización usa medias $(0{,}485; 0{,}456; 0{,}406)$ y desviaciones $(0{,}229; 0{,}224; 0{,}225)$. En validación se usa redimensionamiento y recorte central, sin aumento aleatorio. El muestreo de entrenamiento baraja las fotos; no incorpora un muestreador que equilibre géneros.

(`reports/s5/comparison/configuration.csv`).

(`scripts/train/pipeline/transforms.py`).

Hay una diferencia de entorno además de los ajustes: A se ejecutó en CPU con precisión completa, mientras B/C/D usaron GPU con AMP, que combina precisiones numéricas para acelerar operaciones. El lote de validación de A se reconstruyó del código histórico; B/C/D lo fijan explícitamente. Por ello, A frente a C no constituye por sí solo un experimento que aísle el efecto de ponderar clases. B frente a D sí conserva tasa de aprendizaje, hardware y precisión, aunque sigue siendo una comparación con una sola semilla.

(`reports/s5/comparison/configuration.csv`).

(`reports/s5/comparison/historical_code_audit.json`).

2.3. Resultados en validación

Cuadro 3: Resultados de validación; IC percentil por observación.

Modelo	F1 obs. [IC 95 %]	F1 foto	Acierto obs.
ResNet-18	0,955 [0,945; 0,963]	0,900	95,9 %
MobileNet A	0,971 [0,956; 0,980]	0,925	98,0 %
MobileNet B	0,970 [0,956; 0,979]	0,915	97,7 %
MobileNet C	0,972 [0,964; 0,979]	0,919	97,7 %
MobileNet D	0,962 [0,947; 0,972]	0,913	97,4 %

(`reports/s5/comparison/validation_results.csv`).

Cuadro 4: Duración y selección del checkpoint. Todos los entrenamientos finalizaron por parada temprana; las horas incluyen entrenamiento y validación por época.

Modelo	Mejor vuelta	Vueltas	Horas	Dispositivo / precisión
ResNet-18	11	16	14,80	CPU / FP32
MobileNet A	19	24	14,04	CPU / FP32
MobileNet B	6	11	0,76	GTX 1650 SUPER / AMP
MobileNet C	16	21	1,44	GTX 1650 SUPER / AMP
MobileNet D	7	12	0,84	GTX 1650 SUPER / AMP

(`reports/s5/comparison/validation_results.csv`).

La duración corresponde a la suma del entrenamiento de cada vuelta y su validación. Excluye la preparación inicial de archivos, los periodos de inactividad entre sesiones y la evaluación final. Las historias reanudadas se consolidan por entrenamiento, sin duplicar el tiempo de las vueltas anteriores. Los tiempos deben interpretarse junto con el dispositivo y la precisión numérica utilizados.

(`reports/s5/comparison/validation_results.csv`).

(`reports/s5/comparison/run_inventory.csv`).

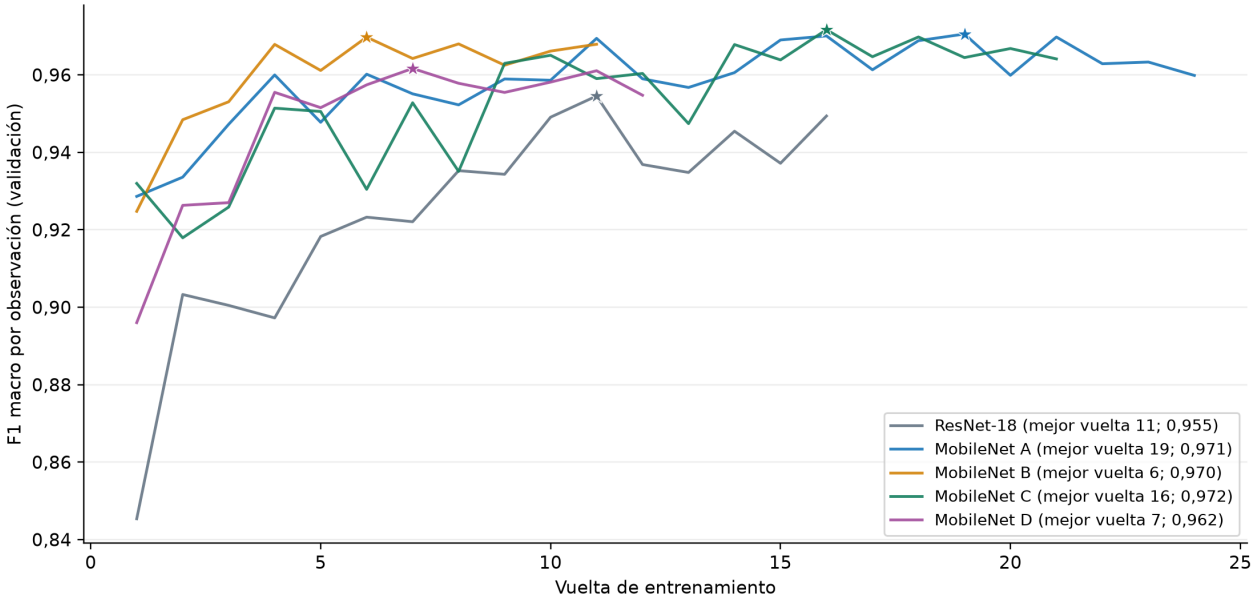


Figura 1: F1 macro por observación de cada vuelta en validación. Las estrellas marcan la mejor vuelta; su número y valor aparecen en la leyenda.
(`reports/s5/comparison/validation_results.csv`).

Las curvas muestran la evolución de la métrica utilizada para seleccionar el modelo. La parada temprana conserva el checkpoint de la mejor vuelta; el modelo finalmente evaluado puede, por tanto, corresponder a una vuelta anterior al cierre del entrenamiento.

(reports/s5/comparison/checkpoint_audit.json).

2.4. Desequilibrio, efecto de los ajustes y cierre de S5

Cuadro 5: Distribución por partición: cantidad entera y porcentaje dentro de la partición y unidad correspondientes.

Género	Train obs.	Train fotos	Val obs.	Val fotos	Test obs.	Test fotos
Amanita	3 752 (21,1 %)	6 508 (21,6 %)	904 (26,2 %)	1 709 (27,2 %)	1 315 (32,6 %)	2 393 (33,4 %)
Auricularia	1 443 (8,1 %)	2 106 (7,0 %)	288 (8,3 %)	411 (6,5 %)	319 (7,9 %)	475 (6,6 %)
Ganoderma	1 832 (10,3 %)	3 567 (11,8 %)	335 (9,7 %)	738 (11,7 %)	346 (8,6 %)	653 (9,1 %)
Geastrum	779 (4,4 %)	1 350 (4,5 %)	79 (2,3 %)	157 (2,5 %)	182 (4,5 %)	377 (5,3 %)
Hericium	494 (2,8 %)	826 (2,7 %)	66 (1,9 %)	114 (1,8 %)	51 (1,3 %)	101 (1,4 %)
Lycoperdon	2 166 (12,2 %)	3 336 (11,1 %)	408 (11,8 %)	686 (10,9 %)	407 (10,1 %)	660 (9,2 %)
Morchella	256 (1,4 %)	405 (1,3 %)	11 (0,3 %)	21 (0,3 %)	20 (0,5 %)	34 (0,5 %)
Pleurotus	1 465 (8,2 %)	2 690 (8,9 %)	251 (7,3 %)	495 (7,9 %)	319 (7,9 %)	616 (8,6 %)
Trametes	3 654 (20,5 %)	6 626 (22,0 %)	756 (21,9 %)	1 421 (22,6 %)	791 (19,6 %)	1 384 (19,3 %)
Xylaria	1 958 (11,0 %)	2 758 (9,1 %)	354 (10,3 %)	538 (8,6 %)	289 (7,2 %)	466 (6,5 %)

(reports/s5/comparison/class_distribution.csv).

Cuadro 6: Totales y razón entre el género más abundante y el menos abundante.

Partición	Observaciones	Fotos	Mayor/menor obs.	Mayor/menor fotos
train	17 799	30 172	14,66	16,36
val	3 452	6 290	82,18	81,38
test	4 039	7 159	65,75	70,38

(reports/s5/comparison/imbalance_ratios.csv).

La métrica macro evita que los géneros grandes dominen el promedio, pero no cambia cuántos ejemplos aprende el modelo. El tratamiento del desequilibrio se prueba explícitamente con la pérdida ponderada de C y D. En entrenamiento la razón entre el género mayor y el menor es 14,66 por observaciones; en validación es 82,18. Por eso un buen promedio global no basta para juzgar las clases pequeñas.

(reports/s5/comparison/imbalance_ratios.csv).

Cuadro 7: F1 por género en validación, a partir de las observaciones.

Género	Obs.	ResNet	A	B	C	D
Amanita	904	0,980	0,992	0,991	0,990	0,992
Auricularia	288	0,959	0,962	0,964	0,962	0,960
Ganoderma	335	0,927	0,962	0,946	0,953	0,947
Geastrum	79	0,933	0,949	0,975	0,958	0,945
Hericium	66	0,922	0,962	0,944	0,930	0,905
Lycoperdon	408	0,938	0,978	0,979	0,978	0,977
Morchella	11	1,000	0,952	0,957	1,000	0,957
Pleurotus	251	0,957	0,978	0,982	0,986	0,978
Trametes	756	0,965	0,984	0,977	0,976	0,972
Xylaria	354	0,965	0,986	0,982	0,983	0,984

(reports/s5/comparison/validation_per_genus.csv).

Cuadro 8: Precisión (P) y recuperación o recall (R), por observación. P baja cuando se asigna el género a hongos de otro género; R baja cuando se omiten hongos del género verdadero.

Género	A: P / R	B: P / R	C: P / R	D: P / R
Amanita	0,992 / 0,991	0,991 / 0,991	0,989 / 0,991	0,994 / 0,989
Auricularia	0,993 / 0,934	0,989 / 0,941	0,996 / 0,931	0,958 / 0,962
Ganoderma	0,953 / 0,970	0,944 / 0,949	0,929 / 0,979	0,931 / 0,964
Geastrum	0,949 / 0,949	0,963 / 0,987	0,919 / 1,000	0,917 / 0,975
Hericium	0,955 / 0,970	1,000 / 0,894	0,952 / 0,909	0,873 / 0,939
Lycoperdon	0,976 / 0,980	0,983 / 0,975	0,988 / 0,968	0,985 / 0,968
Morchella	1,000 / 0,909	0,917 / 1,000	1,000 / 1,000	0,917 / 1,000
Pleurotus	0,969 / 0,988	0,980 / 0,984	0,980 / 0,992	0,969 / 0,988
Trametes	0,980 / 0,987	0,970 / 0,984	0,975 / 0,978	0,982 / 0,962
Xylaria	0,986 / 0,986	0,972 / 0,992	0,986 / 0,980	0,986 / 0,983

(`reports/s5/comparison/validation_per_genus.csv`).

El efecto no es uniforme. C encuentra todas las observaciones de *Morchella* en validación y no produce falsos positivos para ese género; A omite una. Para *Geastrum*, C lleva el recall a 1,000, pero su precisión queda en 0,919 frente a 0,949 de A. En *Hericium*, C tiene recall 0,909 frente a 0,970 de A, y su F1 baja de 0,962 a 0,930. No hay evidencia de que los pesos ayuden a todos los géneros pequeños.

(`reports/s5/comparison/validation_per_genus.csv`).

Entre los géneros grandes, C conserva el recall de *Amanita*, pero reduce su precisión de 0,992 a 0,989. En *Trametes*, tanto precisión como recall son menores que en A. El mayor F1 macro de C convive así con menor exactitud global y menor F1 por foto que A: la elección depende de la métrica principal, no de una mejora en todas las medidas.

(`reports/s5/comparison/validation_per_genus.csv`).

(`reports/s5/comparison/validation_results.csv`).

B y D permiten examinar la ponderación con la misma tasa menor y el mismo entorno. D eleva el recall de *Auricularia* de 0,941 a 0,962 y el de *Hericium* de 0,894 a 0,939, pero reduce sus precisiones de 0,989 a 0,958 y de 1,000 a 0,873, respectivamente. *Morchella* conserva el mismo resultado en ambos. La diferencia macro D menos B es $-0{,}0081$, con IC pareado $[-0{,}0155; -0{,}0012]$: en estas corridas la ponderación con tasa menor empeora esa medida. La conclusión se limita a los modelos entrenados; requiere otras semillas para establecer un efecto reproducible del ajuste.

(`reports/s5/comparison/validation_per_genus.csv`).

(`reports/s5/comparison/bootstrap_paired.csv`).

Los ensayos B, C y D cubren el ajuste de tasa de aprendizaje y la evaluación de una técnica de ponderación para el desequilibrio. Su efecto depende del género y de la tasa utilizada, por lo que el ajuste debe valorarse mediante la métrica principal y el desglose por clase.

(`reports/s5/development_results.json`).

2.5. Comparación de ensayos y elección del modelo

Se recalcularon intervalos al 95 % con 10 000 remuestreos y semilla 42. Cada remuestreo toma, con reposición, el mismo número de observaciones que la partición original. No se remuestrean fotos individualmente. Para comparar modelos se usan **exactamente los mismos identificadores remuestreados** y se calcula la diferencia de F1 dentro de cada remuestreo. Los extremos son los percentiles 2,5 y 97,5; el conjunto de etiquetas se mantiene fijo, asignando cero si un F1 no está definido.

(reports/s5/comparison/analysis_manifest.json).

Cuadro 9: Diferencias por observación. R denota ResNet-18. Intervalos exploratorios sin ajuste por comparaciones múltiples.

Comparación	Diferencia F1	IC 95 % pareado	Incluye cero
A menos R	0,0160	[0,0005; 0,0281]	No
B menos A	-0,0008	[-0,0173; 0,0158]	Sí
B menos R	0,0152	[0,0011; 0,0265]	No
C menos A	0,0011	[-0,0091; 0,0157]	Sí
C menos R	0,0171	[0,0077; 0,0270]	No
D menos A	-0,0089	[-0,0254; 0,0078]	Sí
D menos R	0,0071	[-0,0081; 0,0192]	Sí
C menos B	0,0019	[-0,0084; 0,0161]	Sí
C menos D	0,0100	[-0,0011; 0,0248]	Sí
D menos B	-0,0081	[-0,0155; -0,0012]	No

(reports/s5/comparison/bootstrap_paired.csv).

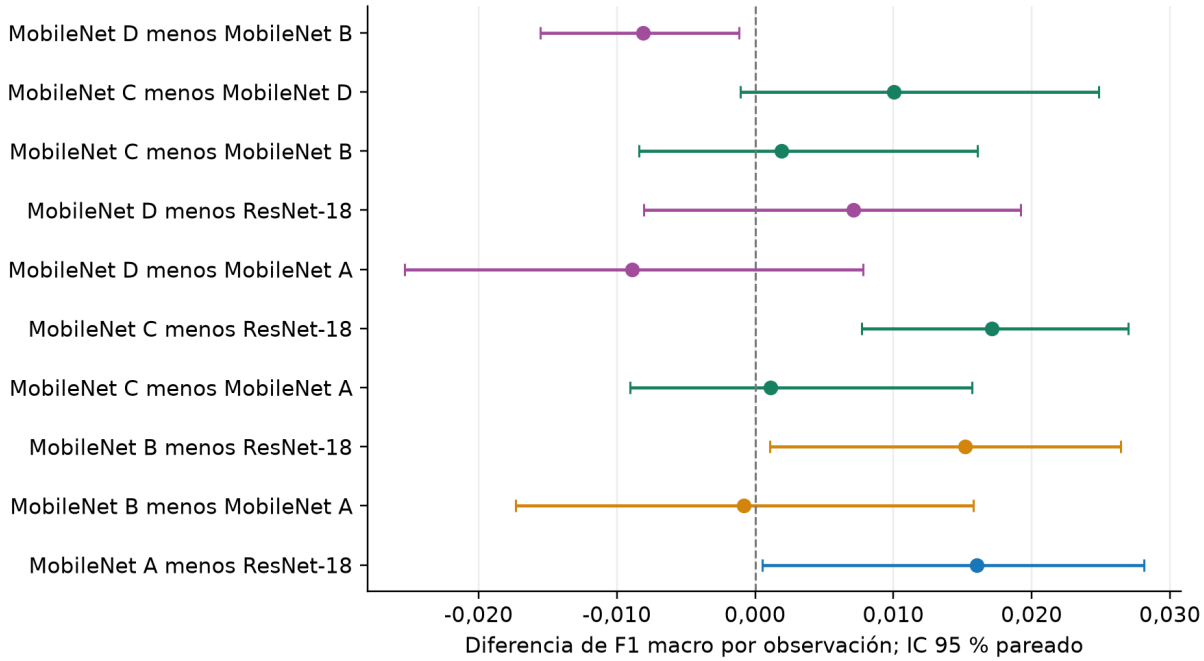


Figura 2: Intervalos pareados de las diferencias. Cuando una barra cruza el cero, esa comparación no distingue el cambio del ruido de muestreo.
(reports/s5/comparison/bootstrap_paired.csv).

Se selecciona C para la evaluación final por tener la mayor F1 macro de validación por observación, 0,971674. Frente a A, la diferencia de 0,001122 tiene IC $[-0{,}009068; 0{,}015696]$ y no se distingue del ruido. Frente a ResNet-18, la diferencia es 0,017131 con IC $[0{,}007721; 0{,}026983]$. No se afirma que C supere de forma concluyente a A.

(reports/s5/comparison/validation_results.csv).

(reports/s5/comparison/bootstrap_paired.csv).

Los criterios móviles no desempatan los MobileNet: conservan arquitectura, parámetros y perfil de ejecución. Se mantiene entonces el criterio operativo de mayor estimación de la métrica principal. C ofrece además un intervalo macro más estrecho en estas observaciones; ello no equivale a estabilidad entre entrenamientos. Sus últimas vueltas varían y la selección conserva el mejor checkpoint, no el

último. Los tiempos de A y C no miden una aceleración controlada porque cambian el dispositivo y el ajuste.

(reports/s5/comparison/profile_ratios.json).

(reports/s5/comparison/validation_results.csv).

Los intervalos individuales de A y ResNet-18 se solapan. Ese solapamiento no sustituye el contraste pareado, que utiliza su correlación sobre los mismos registros. El intervalo de A sigue siendo más ancho aun con mayor F1: en *Morchella*, sus once observaciones incluyen un error, mientras ResNet-18 y C aciertan todas. El bootstrap de F1 de ese género en A abarca [0,824; 1,000], frente a [1,000; 1,000] en los otros dos. Un intervalo degenerado en una clase pequeña perfectamente clasificada no garantiza perfección fuera de la muestra: el remuestreo empírico no puede crear errores que no observó.

(reports/s5/comparison/bootstrap_genus_uncertainty.csv).

(reports/s5/comparison/validation_per_genus.csv).

Estos intervalos describen incertidumbre de muestreo para modelos ya fijados. No incluyen variabilidad de entrenamiento, dependencia entre registros de un mismo sitio y día ni corrección por comparaciones múltiples. La selección de la mejor vuelta también usa esta validación. Por eso los resultados son exploratorios y no reemplazan la evaluación final ni varias semillas.

(reports/s5/comparison/analysis_manifest.json).

La selección de C y las huellas digitales de su checkpoint, configuración y métricas quedan registradas para conservar el modelo elegido hasta su evaluación final en test.

(reports/s5/selected_model.json).

3. Semana 6: resultados por nivel taxonómico

3.1. Taxonomía utilizada

La clasificación sigue los metadatos de FungiTastic: los géneros se agrupan en nueve familias, siete órdenes, tres clases y dos filos. La tabla conserva la asignación original de cada género.

(data/taxonomy/v002/genus_taxonomy.csv).

Cuadro 10: Taxonomía de FungiTastic y número de especies presentes en el dataset.

Género	Familia	Orden	Clase	Filo	Especies
Amanita	Amanitaceae	Agaricales	Agaricomycetes	Basidiomycota	19
Auricularia	Auriculariaceae	Auriculariales	Agaricomycetes	Basidiomycota	2
Ganoderma	Polyporaceae	Polyporales	Agaricomycetes	Basidiomycota	5
Geastrum	Geastraceae	Geastrales	Agaricomycetes	Basidiomycota	9
Hericium	Hericiaceae	Russulales	Agaricomycetes	Basidiomycota	3
Lycoperdon	Lycoperdaceae	Agaricales	Agaricomycetes	Basidiomycota	10
Morchella	Morchellaceae	Pezizales	Pezizomycetes	Ascomycota	3
Pleurotus	Pleurotaceae	Agaricales	Agaricomycetes	Basidiomycota	3
Trametes	Polyporaceae	Polyporales	Agaricomycetes	Basidiomycota	7
Xylaria	Xylariaceae	Xylariales	Sordariomycetes	Ascomycota	5

(data/taxonomy/v002/genus_taxonomy.csv).

En particular, *Ganoderma* está en Polyporaceae, igual que *Trametes*. No se sustituyó esa asignación por Ganodermataceae. Con una clasificación que los separara, su confusión dejaría de contar como acierto familiar y cambiarían las métricas de familia. Los resultados de este informe dependen explícitamente de la decisión taxonómica de FungiTastic.

(data/taxonomy/v002/genus_taxonomy.csv).

3.2. Regla de evaluación jerárquica

Primero se agregan las fotos por observación como se explicó en la sección 1. Luego se toma el género ganador y se consulta su familia, orden, clase o filo. No se entrena otro clasificador ni se suman las probabilidades de todos los géneros de una familia para cambiar la decisión. Por ejemplo, *Ganoderma* confundido con *Trametes* cuenta como error de género y como acierto de familia con la taxonomía adoptada.

(`scripts/train/pipeline/taxonomy.py`).

Con esta regla, un género acertado implica el acierto de todos sus niveles superiores, por lo que la exactitud no puede bajar al agrupar. El F1 macro no tiene esa propiedad: cambia el número de grupos promediados, su peso relativo y los falsos positivos y negativos de cada grupo.

(`scripts/train/pipeline/taxonomy.py`).

3.3. Resultados, intervalos y confusiones

Cuadro 11: Validación por observación: F1 macro y exactitud porcentual con IC 95 % en la propia tabla.

Modelo	**Nivel**	**F1 [IC 95 %]**	**Exactitud, % [IC 95 %]**
ResNet-18	Género	0,955 [0,945; 0,963]	95,9 [95,3; 96,6]
ResNet-18	Familia	0,959 [0,949; 0,968]	96,6 [96,0; 97,2]
ResNet-18	Orden	0,962 [0,951; 0,972]	97,4 [96,9; 97,9]
ResNet-18	Clase	0,987 [0,982; 0,992]	99,3 [99,0; 99,5]
ResNet-18	Filo	0,981 [0,973; 0,988]	99,3 [99,0; 99,5]
MobileNet C	Género	0,972 [0,964; 0,979]	97,7 [97,2; 98,2]
MobileNet C	Familia	0,974 [0,966; 0,981]	98,1 [97,6; 98,5]
MobileNet C	Orden	0,973 [0,963; 0,981]	98,4 [97,9; 98,8]
MobileNet C	Clase	0,994 [0,990; 0,997]	99,7 [99,4; 99,8]
MobileNet C	Filo	0,991 [0,985; 0,996]	99,7 [99,4; 99,8]

(`reports/s6/comparison/taxonomic_summary.csv`).

Los intervalos de ambas medidas se calcularon con el mismo procedimiento y semilla usados para la comparación de ensayos. Los resultados de C corresponden a validación. La tabla siguiente presenta el test histórico del modelo de referencia; la generalización de C se contrastará en su evaluación final.

(`reports/s5/comparison/analysis_manifest.json`).

Cuadro 12: Test histórico de ResNet-18: resultados ya guardados, sin nueva inferencia. No intervienen en la selección de S5.

Modelo	**Nivel**	**F1 [IC 95 %]**	**Exactitud, % [IC 95 %]**
ResNet-18	Género	0,946 [0,933; 0,957]	95,8 [95,1; 96,4]
ResNet-18	Familia	0,950 [0,936; 0,961]	96,4 [95,8; 96,9]
ResNet-18	Orden	0,952 [0,935; 0,966]	97,4 [96,8; 97,8]
ResNet-18	Clase	0,961 [0,930; 0,982]	99,1 [98,8; 99,4]
ResNet-18	Filo	0,968 [0,957; 0,978]	99,1 [98,8; 99,4]

(`reports/s6/comparison/taxonomic_summary.csv`).

En filo, el acierto por observación es de 99,276 % para ResNet-18 en validación, 99,084 % en su test histórico y 99,652 % para C en validación. Son estimaciones observadas; sus intervalos también están en las tablas y no prueban el resultado de C en test.

(`reports/s6/comparison/taxonomic_summary.csv`).

Cuadro 13: Errores de género que se convierten en aciertos al evaluar familia u orden. Las columnas no se suman: misma familia está incluida en mismo orden.

Modelo / partición	Errores de género	Misma familia	Mismo orden
R / val	140	24	51
C / val	80	14	24
R / test	170	24	63

(`reports/s6/comparison/error_hierarchy.csv`).

Cuadro 14: Las cinco confusiones dirigidas más frecuentes de cada evaluación; los empates se ordenan por identificador de clase.

Modelo / partición	Género real	Género predicho	Conteo
R / val	*Amanita*	*Lycoperdon*	22
R / val	*Ganoderma*	*Trametes*	14
R / val	*Trametes*	*Ganoderma*	10
R / val	*Trametes*	*Lycoperdon*	9
R / val	*Ganoderma*	*Xylaria*	6
C / val	*Trametes*	*Ganoderma*	10
C / val	*Auricularia*	*Ganoderma*	7
C / val	*Lycoperdon*	*Amanita*	7
C / val	*Auricularia*	*Trametes*	6
C / val	*Auricularia*	*Pleurotus*	5
R / test	*Amanita*	*Lycoperdon*	26
R / test	*Ganoderma*	*Trametes*	13
R / test	*Trametes*	*Ganoderma*	11
R / test	*Auricularia*	*Xylaria*	10
R / test	*Trametes*	*Lycoperdon*	7

(`reports/s6/comparison/confusion_pairs_top5.csv`).

En validación, C comete 80 errores de género, de los cuales 14 quedan en la misma familia y 24 en el mismo orden. ResNet-18 comete 140, con 24 y 51, respectivamente. La mayoría de los errores sigue cruzando familias; la agrupación taxonómica no elimina toda la dificultad visual.

(`reports/s6/comparison/error_hierarchy.csv`).

Cuadro 15: F1 por taxón que explica las variaciones del promedio al cambiar de nivel (validación).

Modelo	Nivel	Taxón	Obs.	F1
R	Clase	Agaricomycetes	3 087	0,996
R	Clase	Pezizomycetes	11	1,000
R	Clase	Sordariomycetes	354	0,965
R	Filo	Ascomycota	365	0,966
R	Filo	Basidiomycota	3 087	0,996
A	Familia	Amanitaceae	904	0,992
A	Familia	Auriculariaceae	288	0,962
A	Familia	Geastraceae	79	0,949
A	Familia	Hericiaceae	66	0,962
A	Familia	Lycoperdaceae	408	0,978
A	Familia	Morchellaceae	11	0,952
A	Familia	Pleurotaceae	251	0,978
A	Familia	Polyporaceae	1 091	0,989
A	Familia	Xylariaceae	354	0,986
A	Orden	Agaricales	1 563	0,992
A	Orden	Auriculariales	288	0,962
A	Orden	Geastrales	79	0,949
A	Orden	Pezizales	11	0,952
A	Orden	Polyporales	1 091	0,989
A	Orden	Russulales	66	0,962
A	Orden	Xylariales	354	0,986

(`reports/s6/comparison/taxonomic_per_class.csv`).

El caso de A muestra por qué el F1 no siempre aumenta: familia da 0,972118 y orden 0,970486. Al pasar a orden, las familias de *Amanita*, *Lycoperdon* y *Pleurotus* se agrupan como Agaricales; los grupos que permanecen separados cambian su peso en el promedio. Por ejemplo, el F1 0,952 de Morchellaceae/Pezizales pasa de pesar una novena parte a una séptima. Los F1 de cada taxón se muestran arriba; la exactitud de A sí sube de 98,349 % a 98,639 %.

(`reports/s6/comparison/taxonomic_per_class.csv`).

(`reports/s6/comparison/taxonomic_summary.csv`).

En ResNet-18, la clase Pezizomycetes contiene solo *Morchella* y tiene F1 1,000; Sordariomycetes contiene solo *Xylaria* y tiene F1 0,965. Ambas pertenecen a Ascomycota: *Morchella* no está sola en su filo. Al agruparlas, Ascomycota tiene F1 0,966 y Basidiomycota 0,996. Promediar esos dos valores produce F1 0,981, menor que el 0,987 obtenido al promediar las tres clases. No es necesario atribuir la caída a un error adicional: la exactitud de clase y filo es idéntica en esta evaluación.

(`reports/s6/comparison/taxonomic_per_class.csv`).

(`reports/s6/comparison/taxonomic_summary.csv`).

3.4. Especies más difíciles

La selección incluye todas las especies con al menos cinco observaciones y menos de 90 % de acierto de género en al menos un modelo y partición disponibles. Se consideran los modelos de validación y el test histórico de ResNet-18. Por eso puede aparecer una especie con menos observaciones en validación, o sin ellas, si cumple el criterio en el test ya guardado. No se usan estas diferencias de test para elegir al ganador.

(`reports/s6/comparison/species_difficult.csv`).

Cuadro 16: Acierto de género por especie (%). Se incluyen todas las especies con al menos cinco observaciones y menos de 90 % en al menos una evaluación disponible. Un asterisco indica soporte menor de cinco en esa celda; – indica ausencia de observaciones.

Especie	Obs. val	Obs. test	R val	A val	B val	C val	D val	R test previo
Amanita franchetii	3	11	100,0*	100,0*	100,0*	100,0*	100,0*	81,8
Auricularia mesenterica	7	13	42,9	57,1	14,3	57,1	42,9	61,5
Ganoderma applanatum	177	159	88,1	97,2	92,7	97,2	94,4	89,3
Ganoderma lucidum	32	71	93,8	96,9	96,9	96,9	96,9	88,7
Ganoderma resinaceum	14	27	85,7	92,9	92,9	100,0	100,0	92,6
Geastrum melanocephalum	0	7	–	–	–	–	–	85,7
Geastrum striatum	7	22	100,0	85,7	100,0	100,0	85,7	95,5
Hericium cirrhatum	17	15	76,5	88,2	82,4	82,4	94,1	73,3
Lycoperdon mammiforme	2	6	100,0*	100,0*	100,0*	50,0*	100,0*	83,3
Lycoperdon molle	5	6	100,0	100,0	100,0	100,0	100,0	83,3
Morchella esculenta	5	13	100,0	100,0	100,0	100,0	100,0	84,6
Pleurotus dryinus	17	19	94,1	100,0	100,0	100,0	100,0	89,5
Trametes cinnabarina	26	19	76,9	96,2	92,3	92,3	92,3	68,4

(`reports/s6/comparison/species_difficult.csv`).

El desempeño varía de forma importante entre especies de un mismo género. *Auricularia mesenterica* es un caso problemático: A y C aciertan 57,1 %, mientras B acierta 14,3 %, con siete observaciones de validación. Para *Hericium cirrhatum*, D alcanza 94,1 %, A 88,2 % y C 82,4 %, con diecisiete observaciones. El mejor promedio macro no hace que C sea el mejor en cada especie.

(`reports/s6/comparison/species_difficult.csv`).

En entrenamiento hay 149 fotos de *A. mesenterica*, 229 de *H. cirrhatum* y 218 de *T. cinnabarina*. Los conteos permiten estudiar la disponibilidad de ejemplos, pero no prueban que un aspecto distinto al resto del género cause los errores. Esa explicación es una **hipótesis** que requiere una caracterización visual o morfológica para contrastarla.

(`reports/s6/comparison/species_difficult.csv`).

4. Semana 6: organización y control del pipeline

El pipeline separa la carga de datos, las transformaciones de imágenes, la construcción del modelo, el entrenamiento, la evaluación y el almacenamiento de resultados. Esta organización permite reutilizar los componentes visuales cuando se incorporen variables ambientales y facilita reproducir las comparaciones con una configuración explícita.

(`scripts/train/pipeline/`).

La admisión de una corrida al análisis exige que haya completado el entrenamiento, cubra la partición correspondiente y contenga probabilidades finitas y válidas. Las ejecuciones iniciales de B/C/D que no cumplieron esta condición se excluyeron de la comparación. Los resultados presentados corresponden a las ejecuciones posteriores válidas, cuya validación utiliza lotes de 64 imágenes.

(`reports/s5/comparison/run_inventory.csv`).

(`scripts/train/pipeline/predictions.py`).

Las métricas por observación se reconstruyeron a partir de las probabilidades guardadas y reprodujeron las matrices de confusión originales. Se comprobó también la correspondencia entre clases, particiones y checkpoints. Estas comprobaciones respaldan la consistencia del análisis.

(`reports/s5/comparison/analysis_manifest.json`).

La selección conserva el checkpoint elegido y las huellas digitales de la configuración y de sus resultados de validación. El procedimiento de evaluación final utiliza esa selección registrada y controla que la campaña consulte test una sola vez.

(reports/s5/selected_model.json).

(scripts/train/evaluate_s5_final.py).

5. Conclusiones y trabajo futuro

MobileNetV3-Large requiere menos espacio y menor latencia de referencia en CPU que ResNet-18. Se selecciona C para la evaluación final por su mayor estimación de F1 macro por observación. La comparación pareada no permite concluir una ventaja sobre A; la elección sigue la métrica principal.

(reports/s5/comparison/profile_ratios.json).

(reports/s5/comparison/validation_results.csv).

(reports/s5/comparison/bootstrap_paired.csv).

La ponderación de clases implica intercambios entre precisión y recuperación que varían según el género y la tasa de aprendizaje. La mayoría de los errores de género cruza familias; por ello, el F1 macro debe complementarse con resultados desglosados por género y especie.

(reports/s5/comparison/validation_per_genus.csv).

(reports/s6/comparison/error_hierarchy.csv).

(reports/s6/comparison/species_difficult.csv).

El alcance de estas conclusiones corresponde a una semilla por configuración y al conjunto de observaciones evaluado. Los intervalos cuantifican incertidumbre de muestreo; la variación entre entrenamientos requiere réplicas independientes. Asimismo, el cambio de CPU a GPU entre A y los otros ensayos limita la atribución causal de sus diferencias a un único hiperparámetro.

(reports/s5/comparison/configuration.csv).

(reports/s5/comparison/analysis_manifest.json).

Las siguientes actividades consolidarán la evaluación y su aplicación móvil:

1. **Evaluación final de C.** Ejecutar una única consulta de test con el checkpoint seleccionado y analizar F1, exactitud, intervalos, confusiones y comportamiento por especie.
   (reports/s5/selected_model.json).
2. **Validación en Android.** Medir el modelo desplegado en un dispositivo real, registrando el motor de ejecución, la latencia, el consumo de memoria y el tamaño del artefacto. Esta medición permitirá contrastar el perfil de CPU con las condiciones de uso de la aplicación.
   (reports/s5/architecture_profile.json).
3. **Estabilidad de los ajustes.** Repetir las configuraciones con otras semillas y un entorno común para estimar la variación del entrenamiento y aislar el efecto de la tasa de aprendizaje y de la ponderación.
   (reports/s5/comparison/configuration.csv).
4. **Análisis de errores e integración ambiental.** Examinar las especies con menor recuperación mediante revisión visual o morfológica y utilizar el pipeline modular como base para incorporar información ambiental en la siguiente fase del proyecto.
   (reports/s6/comparison/species_difficult.csv).
   (scripts/train/pipeline/).

A. Trazabilidad de los resultados

Cuadro 17: Correspondencia entre las claves del informe y las corridas completas.

Clave	Carpeta de la corrida usada
R	runs/20261004T133123181686Z_ma_resnet18_v002
A	runs/20261012T161041257797Z_s5_mobilenet_v3_large_v002_a
B	runs/20261024T022849507889Z_s5_mobilenet_v3_large_v002_b
C	runs/20261024T031650621510Z_s5_mobilenet_v3_large_v002_c
D	runs/20261024T132723373718Z_s5_mobilenet_v3_large_v002_d

(reports/s5/comparison/validation_results.csv).

Las corridas utilizadas comparten la huella del dataset publicado, las particiones, los identificadores de validación y el orden de géneros. Las predicciones por observación se obtienen mediante el promedio de probabilidades de sus fotografías. Los archivos derivados permiten reproducir las métricas y las comparaciones presentadas.

(reports/s5/comparison/analysis_manifest.json).

Cuadro 18: Corridas completas excluidas: cada una contiene probabilidades no finitas en 6 272 de 6 290 fotos de validación.

Ensayo	Corrida excluida
B	runs/20261023T005149730394Z_s5_mobilenet_v3_large_v002_b
C	runs/20261023T020544245443Z_s5_mobilenet_v3_large_v002_c
D	runs/20261024T015337199324Z_s5_mobilenet_v3_large_v002_d

(reports/s5/comparison/run_inventory.csv).

Las carpetas de origen de una reanudación forman parte del mismo entrenamiento. En D, la continuación conserva las vueltas anteriores y el checkpoint seleccionado, por lo que sus tiempos se contabilizan una sola vez.

(reports/s5/comparison/run_inventory.csv).

(reports/s5/comparison/checkpoint_audit.json).

El material reproducible comprende las tablas de configuración y resultados, las predicciones derivadas por observación, las figuras y los scripts de análisis. El registro técnico conserva las exclusiones, las comprobaciones y los comandos necesarios para regenerar estos productos.

(reports/s5/comparison/AUDITORIA_Y_REPRODUCCION.md).

(scripts/reports/analyze_s5_s6.py).

(scripts/reports/build_s5_s6_tables.py).